

# Qwen2.5-Coder LoRA Fine-Tuning Proje Raporu

Öğrenci Adı: Çağla DEMİR

Öğrenci No: 2020556018

Tarih: 29 Kasım 2024

Konu: Large Language Model (LLM) Fine-Tuning for Competitive Code Reasoning

## 1. Proje Özeti

Bu projenin amacı, **Qwen2.5-Coder-1.5B-Instruct** temel modelinin kodlama ve mantıksal muhakeme (reasoning) yeteneklerini, **LoRA (Low-Rank Adaptation)** teknigi kullanarak geliştirmektir. Proje kapsamında model, iki farklı veri seti (**DEEP** ve **DIVERSE**) üzerinde eğitilmiş ve sonuçlar Hugging Face platformunda yayınlanmıştır.

Eğitim sürecinde Google Colab (T4 GPU) donanım kısıtlamaları göz önünde bulundurularak hafıza optimizasyonu sağlayan teknikler (Gradient Checkpointing, Quantization) uygulanmıştır.

## 2. Kullanılan Model ve Veri Setleri

- **Base Model:** Qwen/Qwen2.5-Coder-1.5B-Instruct
  - Seçim Nedeni: Kodlama görevlerinde yüksek performans göstermesi ve 1.5B parametre boyutuyla T4 GPU üzerinde eğitilebilir olması.
- **Datasets:**
  1. **DEEP Dataset:** Karmaşık mantık yürütme (reasoning trace) gerektiren kodlama problemleri.
  2. **DIVERSE Dataset:** Çeşitli konu başlıklarını kapsayan geniş yelpazeli kodlama problemleri.

## 3. Eğitim Konfigürasyonu (Hyperparameters)

Eğitim sırasında dokümanda önerilen ve donanım kısıtlarına uygun aşağıdaki hiperparametreler kullanılmıştır:

Parametre	Değer	Açıklama
LoRA Rank (r)	16	Parametre verimliliği için seçildi.
LoRA Alpha	32	$r * 2$ kuralına uygun olarak belirlendi.
Target Modules	All Linear	q_proj, k_proj, v_proj, o_proj, gate_proj, up_proj, down_proj .
Learning Rate	2e-4	Kararlı bir öğrenme süreci için seçildi.
Batch Size	1	GPU belleğini (VRAM) aşmamak için düşürüldü.
Gradient Accumulation	16	Efektif batch size'ı 16'ya tamamlamak için kullanıldı.
Context Length	1024	Sadece çözüm (code-only) eğitimi yapıldığı için yeterli görüldü.
Precision	FP16	Mixed Precision eğitimi yapıldı.
Optimizer	AdamW	Paged AdamW 32bit.

## 4. Karşılaşılan Zorluklar ve Çözümler

Proje geliştirme sürecinde, dokümanda belirtilen "Sık Karşılaşılan Sorunlar" yaşanmış ve şu çözümler uygulanmıştır:

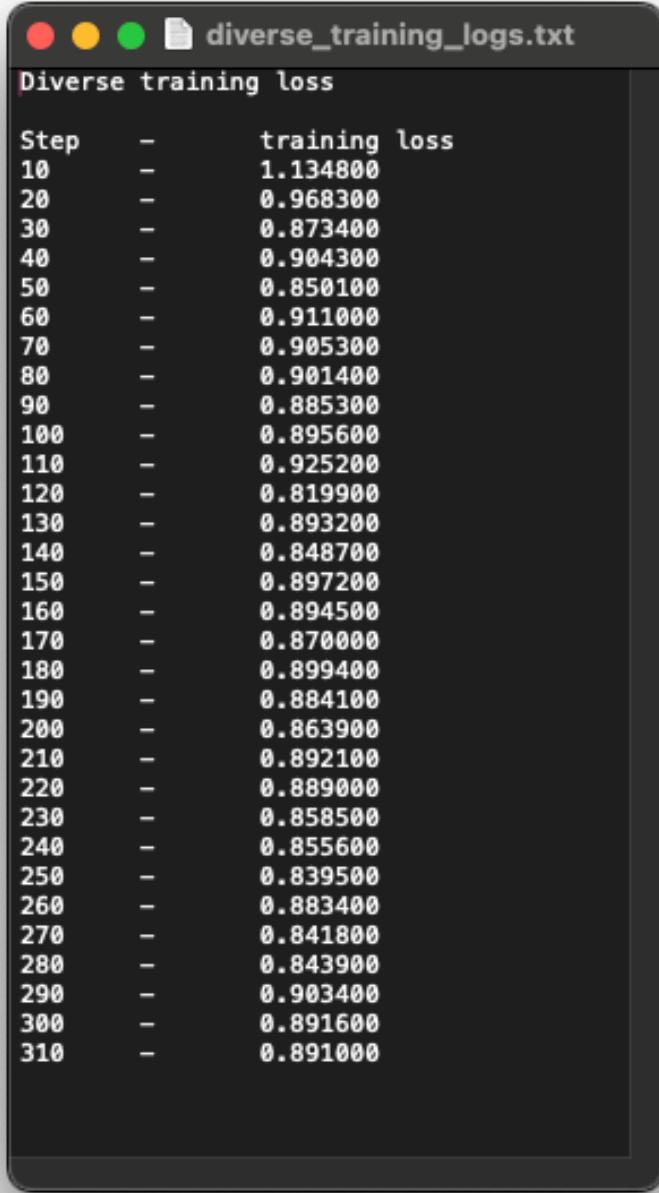
- **CUDA Out of Memory (OOM) Hatası:** Google Colab T4 GPU'nun 16GB VRAM kapasitesi, standart eğitim ayarları için yetersiz kalmıştır.
  - **Çözüm:** `per_device_train_batch_size` 1'e düşürülmüş ve `gradient_accumulation_steps` 16'ya çıkarılarak bellek kullanımı dengelenmiştir. Ayrıca `gradient_checkpointing=True` yapılarak aktivasyonların bellekte tutulması engellenmiş, işlemci yükü artırılarak bellekten tasarruf edilmiştir<sup>13</sup>.
- **Eğitim Takibi:** Google Colab oturum süreleri kısıtlı olduğu için modellerin kaybolma riski oluşmuştur.
  - **Çözüm:** Eğitim çıktıları (`output_dir`) doğrudan Google Drive'a yönlendirilmiş, böylece olası bağlantı kopmalarında modelin kaybolması engellenmiştir.

## 5. Eğitim Sonuçları ve Kayıtlar (Logs)

Eğitim boyunca Loss (Kayıp) değerlerinin düzenli olarak düştüğü gözlemlenmiştir.

```
deep training loss

Step      -      training loss
10       -      1.092200
20       -      0.962500
30       -      0.875100
40       -      0.861700
50       -      0.835900
60       -      0.889100
70       -      0.871300
80       -      0.901800
90       -      0.855500
100      -      0.838700
110      -      0.784800
120      -      0.809100
130      -      0.816300
140      -      0.813300
150      -      0.782200
160      -      0.781300
170      -      0.755600
180      -      0.779100
190      -      0.736400
200      -      0.737700
210      -      0.755700
220      -      0.719200
230      -      0.709900
240      -      0.728600
250      -      0.733500
260      -      0.694100
270      -      0.688100
280      -      0.730300
290      -      0.722000
300      -      0.679200
310      -      0.702100
```



Diverse training loss

Step	training loss
10	1.134800
20	0.968300
30	0.873400
40	0.904300
50	0.850100
60	0.911000
70	0.905300
80	0.901400
90	0.885300
100	0.895600
110	0.925200
120	0.819900
130	0.893200
140	0.848700
150	0.897200
160	0.894500
170	0.870000
180	0.899400
190	0.884100
200	0.863900
210	0.892100
220	0.889000
230	0.858500
240	0.855600
250	0.839500
260	0.883400
270	0.841800
280	0.843900
290	0.903400
300	0.891600
310	0.891000

Eğitim sonunda, Loss değerinin en düşük olduğu **Final Checkpoint**, en başarılı model olarak kabul edilmiştir.

## 6. Proje Teslimatları

Eğitilen modeller ve kaynak kodlar aşağıdaki bağlantılarla erişime açıktır:

- GitHub Repository (Kodlar ve Rapor):  
<https://github.com/caglademir/Qwen2.5-LoRA-FineTuning>
- Hugging Face Model - DEEP:  
<https://huggingface.co/datasets/Naholav/CodeGen-Deep-5K>
- Hugging Face Model - DIVERSE:  
<https://huggingface.co/datasets/Naholav/CodeGen-Diverse-5K>

---

**Not:** Benchmark değerlendirmesi, test veri seti yayınlandığında gerçekleştirilecek ve sonuçlar bu rapora eklenecektir.